

Phân tích các yếu tố ảnh hưởng đến sự hài lòng của khách hàng đối với khách sạn

Bùi Quốc Bảo ^{1,2}, Lê Minh Khôi ^{1,2}, Huỳnh Phát Đạt ^{1,2}, Đỗ Trọng Hợp ^{1,3}

¹ Trường Đại học Công Nghệ Thông Tin

² {23520091, 23520767, 24520270} @gm.uit.edu.vn

³ {hopdt} @uit.edu.vn

Tóm tắt. Đồ án tập trung vào việc phân tích một cách toàn diện các yếu tố ảnh hưởng đến mức độ hài lòng của khách hàng đối với các cơ sở lưu trú ven biển, nằm tại các thành phố du lịch lớn và các huyện đảo nổi tiếng ở Việt Nam. Phục vụ cho mục tiêu này, dữ liệu được thu thập từ trang web Booking.com thông qua kỹ thuật web scraping sử dụng Selenium với Python. Bộ dữ liệu thu thập bao gồm các đặc trưng quan trọng của khách sạn như vị trí, tiện nghi, khoảng cách đến trung tâm hoặc bãi biển, số sao, loại hình lưu trú, điểm đánh giá, số lượng đánh giá và nhiều yếu tố mô tả khác. Sau khi thu thập, dữ liệu được tiến hành tiền xử lý để đảm bảo tính sạch, cấu trúc và sẵn sàng cho quá trình phân tích chuyên sâu về các yếu tố ảnh hưởng đến sự hài lòng của khách hàng. Trong quá trình phân tích dữ liệu và khám phá dữ liệu, các kỹ thuật kiểm định thống kê như kiểm định t (Two-sample t-test), ANOVA một chiều, và kiểm định hậu kiểm (post-hoc) được sử dụng nhằm xác định các yếu tố có ảnh hưởng đáng kể về mặt thống kê đến mức độ hài lòng của khách hàng, được đo lường thông qua điểm đánh giá trung bình của khách hàng để lại cho từng khách sạn. Các biến không có ý nghĩa thống kê được loại bỏ nhằm làm sạch dữ liệu và giảm nhiễu. Sau cùng, mô hình hồi quy tuyến tính được triển khai để lượng hóa mức độ ảnh hưởng của từng yếu tố còn lại đến sự hài lòng. Mô hình giúp xác định rõ yếu tố nào có tác động tích cực, tiêu cực và mức độ ảnh hưởng cụ thể, qua đó cung cấp các gợi ý định hướng cải thiện dịch vụ cho các đơn vị cung cấp lưu trú. Kết quả phân tích cho thấy một số đặc trưng như giá phòng, số sao, loại phòng ở, các tiện nghi như hồ bơi, phòng tập thể dục, một số địa điểm du lịch nhất định có tương quan mạnh với mức độ hài lòng của khách hàng. Đề tài nhấn mạnh vai trò quan trọng của việc xử lý dữ liệu và ứng dụng các phương pháp phân tích thống kê trong việc đưa ra các kết luận đáng tin cậy và có giá trị thực tiễn.

1 Giới thiệu

Trong ngành du lịch – khách sạn, mức độ hài lòng của khách hàng là yếu tố sống còn quyết định đến khả năng cạnh tranh, tỷ lệ quay lại và danh tiếng của cơ sở lưu trú. Trong thời đại số, khi hành vi đặt phòng của khách hàng chịu ảnh hưởng lớn từ các đánh giá và xếp hạng trực tuyến, việc hiểu rõ các yếu tố ảnh hưởng đến sự hài lòng không chỉ mang ý nghĩa tham khảo mà còn là nền tảng để đưa ra quyết định quản lý, điều chỉnh dịch vụ và chiến lược kinh doanh.


Tuy nhiên, trên thực tế, nhiều đơn vị kinh doanh lưu trú vẫn thiếu công cụ và dữ liệu để đánh giá một cách định lượng đâu là những yếu tố quan trọng nhất trong trải nghiệm của khách hàng. Các quyết định cải tiến dịch vụ phần lớn vẫn dựa trên cảm tính hoặc phản hồi rời rạc, thiếu hệ thống. Điều này dẫn đến việc đầu tư không hiệu quả hoặc bỏ lỡ cơ hội cải thiện những điểm chạm quan trọng trong hành trình khách hàng.

Xu hướng hiện nay đặt ra yêu cầu cấp thiết về việc khai thác dữ liệu thực tế từ các nền tảng trực tuyến để phân tích hành vi, cảm nhận và mức độ hài lòng của khách du lịch. Việc ứng dụng các phương pháp phân tích thống kê và mô hình hóa dữ liệu không chỉ giúp lượng hóa ảnh hưởng của từng yếu tố như giá cả, vị trí, tiện nghi, loại hình lưu trú hay mức độ phục vụ, mà còn mở ra hướng tiếp cận khoa học, chính xác hơn trong việc nâng cao chất lượng dịch vụ.

Từ đó, có thể thấy rằng việc nghiên cứu và phân tích các yếu tố ảnh hưởng đến sự hài lòng của khách hàng không chỉ mang ý nghĩa học thuật, mà còn có tính ứng dụng

thực tiễn cao trong quản trị khách sạn, xây dựng hệ thống gợi ý cho các nền tảng đặt phòng, cũng như hỗ trợ các nhà đầu tư và nhà quản lý trong việc ra quyết định dựa trên dữ liệu.

2 Phương pháp




2.1 Khảo sát

Trước khi thu thập, nhóm tham khảo một số bộ dữ liệu và dự án khách sạn trên Kaggle, GitHub như TBO Hotels, Airbnb Price Prediction, Hotel Booking Demand,... để xác định các đặc trưng cơ bản như tên, vị trí, loại hình lưu trú, số sao, giá, đánh giá và tiện nghi. Tuy nhiên, các bộ dữ liệu này thường thiếu thông tin quan trọng như khoảng cách địa lý, loại view, tiện ích như hồ bơi, đưa đón sân bay và đánh giá chi tiết. Vì vậy, nhóm xây dựng hệ thống thu thập dữ liệu tự động nhằm tạo bộ dữ liệu đầy đủ và chi tiết, phản ánh toàn diện các yếu tố ảnh hưởng đến sự hài lòng của khách hàng.

2.2 Thu thập dữ liệu


Nhóm thu thập dữ liệu từ trang Booking.com – nền tảng đặt phòng phổ biến với thông tin khách sạn phong phú. Do trang sử dụng cơ chế tải động, nhóm áp dụng phương pháp web scraping bằng Selenium để tự động điều khiển trình duyệt, truy cập và trích xuất dữ liệu.

Hệ thống truy cập Booking.com, chọn danh mục “Bãi biển” để thu thập danh sách các địa điểm du lịch biển như thành phố, huyện đảo. Tại mỗi địa điểm, hệ thống cuộn trang để tải toàn bộ danh sách khách sạn, trích xuất các thông tin cơ bản như tên, địa chỉ, giá phòng, khoảng cách, số sao, đánh giá,... và lưu lại liên kết đến từng khách sạn.



Hình 1: Trang danh sách thực hiện thu thập các thông tin cơ bản

Tiếp theo, hệ thống lần lượt truy cập vào từng khách sạn để lấy thêm các đặc trưng chi tiết như loại view, tiện nghi nổi bật, khoảng cách đến sân bay, số lượng địa điểm gần đó và đánh giá theo từng khía cạnh như sạch sẽ, tiện nghi, vị trí, đáng tiền,...



Hình 2: Thông tin chi tiết thu thập trong từng trang khách sạn

Dữ liệu cơ bản và chi tiết sau cùng được gộp lại thành một bảng duy nhất, tương ứng với tầng Bronze trong kiến trúc Medallion, làm đầu vào cho bước tiền xử lý tiếp theo.

2.3 Tiền xử lý dữ liệu

Tiền xử lý là bước quan trọng nhằm chuyển dữ liệu thô (tầng Bronze) thành dữ liệu sạch, có cấu trúc (tầng Silver), sẵn sàng cho phân tích và mô hình hóa. Nhóm thực hiện các thao tác như chuẩn hóa định dạng, xử lý dữ liệu thiếu, loại bỏ nhiễu, quy đổi đơn vị, mã hóa biến phân loại và trích xuất đặc trưng từ văn bản...

2.3.1 Xử lý tổng thể

Dữ liệu được làm sạch bằng cách loại bỏ dòng trống, chuẩn hóa chuỗi văn bản, thay thế các giá trị trống bằng NaN và loại bỏ dòng có giá trị thiếu (nếu dưới 5%). Sau đó, dữ liệu được kiểm tra lại để đảm bảo tính đồng nhất.

2.3.2 Chuẩn hóa dữ liệu

Các trường như địa chỉ được xử lý để giữ lại tên địa điểm chính. Khoảng cách được quy đổi về km, giá phòng được trích xuất số và chuyển về dạng số thực. Đánh giá văn bản như “Tuyệt vời”, “Tốt” được mã hóa thứ bậc. Các trường định lượng khác được chuẩn hóa dấu thập phân. Dữ liệu trùng lặp được loại bỏ bằng cách dùng `drop_duplicates` trên tên khách sạn.

2.3.3 Trích xuất đặc trưng

Các trường văn bản phức tạp như kind (loại hình lưu trú) được chuẩn hóa ngôn ngữ và từ khóa, sau đó trích xuất thành hai trường mới là `Accommodation_Type` (phòng, căn hộ, biệt thự,...) và `Room_Level` (tiêu chuẩn, deluxe,...). Các thông tin này được tạo thành một cột riêng, còn cột kind gốc bị loại bỏ để tránh dư thừa.

Sau tiền xử lý, dữ liệu đã được làm sạch, chuẩn hóa và trích xuất đầy đủ đặc trưng, đạt chuẩn tầng Silver trong kiến trúc Medallion. Dữ liệu không còn nhiễu, định dạng thống nhất, giá trị thiếu được xử lý hợp lý và các trường phức tạp đã được tách rõ ràng, sẵn sàng cho các bước phân tích thống kê và khám phá.

2.4 Khám phá và phân tích dữ liệu

Sau khi hoàn tất giai đoạn tiền xử lý và lưu trữ dữ liệu ở tầng Silver, nhóm tiến hành bước EDA nhằm khám phá, hiểu rõ đặc trưng dữ liệu và chuẩn bị cho việc xây dựng tập dữ liệu đầu vào cuối cùng cho mô hình, tức tầng Gold. Quá trình này không chỉ giúp phát hiện các điểm bất thường, xu hướng ẩn và mối liên hệ giữa các biến, mà còn góp phần tinh gọn và lựa chọn các đặc trưng có giá trị với biến mục tiêu của chúng ta, ở đây là biến Point biểu thị cho sự hài lòng của khách hàng đối với khách sạn

Nhóm bắt đầu bằng việc loại bỏ thuộc tính Evaluate do có mối quan hệ trực tiếp với biến mục tiêu Point. Tiếp đó, nhóm khảo sát phân phối của Point bằng biểu đồ boxplot để kiểm tra sự phân bố và xác định các giá trị bất thường.

2.4.1 Sự tương quan của các trường dữ liệu

Nhóm phân tích ma trận tương quan giữa các biến định lượng liên tục như Distance_to_DownTown, Distance_to_Beach, Price, Stars, tourist_spot,... nhằm kiểm tra tính tuyến tính và loại bỏ đa cộng tuyến. Dựa trên mức độ tương quan cao giữa một số thuộc tính, nhóm giữ lại những biến đại diện và loại bỏ các biến trùng lặp thông tin. Đồng thời, nhóm xác định các biến có tương quan cao với biến mục tiêu Point để ưu tiên sử dụng trong các bước tiếp theo.

2.4.2 Phân tích các trường dữ liệu nhị phân

Trong bước phân tích này, nhóm tập trung khảo sát mức độ ảnh hưởng của các trường dữ liệu dạng nhị phân như pool, view_to_beach, airport_shuttle... đến điểm đánh giá. Mục tiêu là đánh giá xem sự có hay không của một tiện ích cụ thể có dẫn đến chênh lệch đáng kể về điểm đánh giá hay không, qua đó phục vụ việc lựa chọn đặc trưng đầu vào cho mô hình học máy.

Để đánh giá, nhóm áp dụng kiểm định t hai mẫu độc lập (two sample t-test). Đây là một phương pháp thống kê được sử dụng để kiểm tra xem trung bình của hai nhóm độc lập có khác biệt một cách có ý nghĩa hay không. Nói cách khác, t-test trả lời cho câu hỏi “liệu sự khác biệt trung bình quan sát được giữa hai nhóm là thực sự tồn tại, hay chỉ là do ngẫu nhiên trong quá trình lấy mẫu”.

Công thức tổng quát của kiểm định t hai mẫu độc lập là:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Trong đó:

- $\bar{X}_1, \bar{X}_2$: trung bình mẫu của hai nhóm.
- s_1^2, s_2^2 : phương sai mẫu.
- n_1, n_2 : kích thước mẫu tương ứng.

Từ kiểm định t, nhóm tính khoảng tin cậy 95% cho hiệu trung bình giữa hai nhóm để có cái nhìn trực quan và đáng tin cậy hơn về mức độ chênh lệch điểm đánh giá, tránh sự chênh lệch là quá nhỏ, không đáng kể. Khoảng tin cậy là một khoảng giá trị được xây dựng từ dữ liệu mẫu, giúp ước lượng phạm vi mà giá trị trung bình thực sự của tổng thể có khả năng nằm trong đó, với xác suất mà nhóm sử dụng là 95%.


Công thức tổng quát của khoảng tin cậy cho hiệu trung bình là:

$$CI = (\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Trong đó:

- $(\bar{X}_1 - \bar{X}_2)$: hiệu trung bình giữa hai nhóm.
- $z_{\alpha/2}$: giá trị tới hạn từ phân phối chuẩn.
- Biểu thức dưới căn là sai số chuẩn của hiệu trung bình.

Để đảm bảo giả định phân phối điểm đánh giá trong mỗi nhóm là gần chuẩn trước khi thực hiện kiểm định two sample t-test, nhóm tiến hành trực quan và điều chỉnh để phân phối điểm đánh giá trong mỗi nhóm có thể đạt trạng thái gần chuẩn, giúp kết quả kiểm định thống kê đáng tin cậy hơn.



Hình 3: Phân phối điểm đánh giá của thuộc tính trước điều chỉnh

2.4.3 Phân tích các thuộc tính phân loại

Trong bước này, nhóm tiến hành phân tích các thuộc tính mang bản chất phân loại. Mục tiêu của bước này là xác định xem các biến phân loại này có ảnh hưởng đến biến target hay không.

Để thực hiện, nhóm tiến hành kiểm định ANOVA một chiều (one-way ANOVA) cho từng biến phân loại. Đây là một phương pháp thống kê được sử dụng để kiểm tra xem trung bình của biến target có khác nhau giữa các nhóm của một biến phân loại hay không. Ý tưởng cốt lõi của phương pháp kiểm định này là so sánh độ biến thiên giữa các nhóm (Between-group variability) và độ biến thiên trong từng nhóm (Within-group variability). Nếu độ biến thiên giữa các nhóm lớn hơn đáng kể so với độ biến thiên trong nhóm thì có sự khác biệt trung bình.

ANOVA sử dụng thống kê F - test:

$$F = \frac{(\text{between} - \text{group variance})}{(\text{within} - \text{group variance})}$$

Trong đó:

- *between - group variance*: phương sai giữa các nhóm.
- *within - group variance*: phương sai trong mỗi nhóm.

Phương pháp này đặt ra 2 giả thuyết :

- H_0 (Null Hypothesis): các nhóm có cùng trung bình
- H_1 (Alternative): có ít nhất 1 nhóm có trung bình khác biệt

Dựa vào giá trị F sẽ tính được p-value, nếu p-value nhỏ hơn mức ý nghĩa 5%, nhóm sẽ tiến hành bác bỏ H_0 (tức biến phân loại không có ảnh hưởng đến biến mục tiêu) hoặc ngược lại.

Sau khi đã tiến hành kiểm định one-way ANOVA và xác định được biến nhị phân nào có ảnh hưởng đến biến mục tiêu (tức có sự khác biệt giữa các nhóm). Để biết được cặp nhóm nào khác nhau về mặt thống kê, nhóm tiến hành kiểm định hậu nghiệm (Post hoc analysis), phép kiểm định nhóm dùng là Turkey's HSD. Turkey's HSD sẽ kiểm tra sự khác biệt trung bình giữa mỗi cặp nhóm với mục tiêu là để tính gọn và chọn lọc ra được những nhóm thực sự ảnh hưởng đến biến mục tiêu.

Cách Turkey's HSD kiểm tra trung bình mỗi 2 nhóm i,j:

$$q = \frac{|y_{bari} - y_{barj}| \times \sqrt{2}}{(\sqrt{MSE} \times \sqrt{\frac{1}{n_i} + \frac{1}{n_j}})}$$

Trong đó :

- y_{bari} : trung bình nhóm i
- y_{barj} : trung bình nhóm j
- MSE : trung bình của bình phương sai số nội nhóm
- n_i : số phần tử nhóm i
- n_j : số phần tử nhóm j

Nhóm so sánh p-value với mức ý nghĩa 5% do nhóm đặt ra, nếu nhỏ hơn thì bác bỏ H_0 (tức 2 nhóm có trung bình khác nhau) hoặc chấp nhận H_0 (tức 2 nhóm có cùng trung bình) nếu ngược lại. Nếu 2 nhóm có cùng trung bình, tiến hành gộp thành một nhóm.

Sau khi đã thực hiện việc chọn lọc đặc trưng và gom nhóm, nhóm một lần nữa tiến hành kiểm tra chỉ số VIF (Variance Inflation Vector) – hệ số phóng đại phương sai với mục tiêu kiểm tra hiện tượng đa cộng tuyến. Từ đó, loại bỏ các biến độc lập có chỉ số VIF >10 để đảm bảo không còn xảy ra hiện tượng đa cộng tuyến.

2.5 Mô hình, độ đo và kiểm định đánh giá

2.5.1 Linear Regression (Hồi quy tuyến tính)

Linear Regression là một trong những mô hình cơ bản nhất trong học máy và thống kê, được sử dụng để mô hình hóa mối quan hệ tuyến tính giữa các biến đầu vào (các đặc trưng) và biến đầu ra (điểm đánh giá của khách hàng). Mô hình tìm ra một đường thẳng (trong không gian nhiều chiều) sao cho sai số giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất. Mô hình học một hàm số tuyến tính dưới dạng:

$$y = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

- y : giá khách sạn dự đoán
- x_i : các đặc trưng đầu vào như số sao, vị trí, điểm đánh giá, tiện nghi,...
- w_i : hệ số của từng đặc trưng.
- b : hệ số chệch (bias)

Mô hình này phù hợp với dữ liệu có mối quan hệ tuyến tính rõ ràng và ít nhiễu.

2.5.2 Mean Absolutely Error (MAE)

MAE đo mức độ sai lệch trung bình giữa giá trị dự đoán và giá trị thực tế, bằng cách lấy trị tuyệt đối sai số cho từng mẫu và tính trung bình:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

MAE dễ hiểu, dễ diễn giải trong bài toán dự đoán giá khách sạn mà nhóm thực hiện. Không bị ảnh hưởng quá mức bởi các ngoại lệ (outliers) như MSE. Đơn vị của MAE giống với đơn vị biến mục tiêu (vd: ngàn đồng, triệu đồng).

2.5.3 Adjusted R-squared (R2 hiệu chỉnh)

Adjusted R-squared là phiên bản đã điều chỉnh của R^2 , giúp đánh giá mức độ phù hợp của mô hình hồi quy với dữ liệu, đồng thời có tính đến số lượng biến độc lập trong mô hình:

$$R_{adj}^2 = 1 - (1 - R^2) \cdot \frac{n - 1}{n - p - 1}$$

- n : Số lượng mẫu
- p : Số lượng biến độc lập
- R^2 : Hệ số xác định thông thường (R-squared) - cho biết mô hình giải thích được bao nhiêu phần trăm phương sai của dữ liệu.
- R_{adj}^2 tăng khi thêm biến có ý nghĩa thống kê.
- R_{adj}^2 giảm nếu thêm biến không mang lại cải thiện thực sự. Do đó, nó giúp tránh hiện tượng overfitting và phản ánh chính xác hơn hiệu quả của mô hình

2.5.4 ANOVA F-test hồi quy

ANOVA F-test (Analysis of Variance for Regression) là một phương pháp kiểm định thống kê nhằm đánh giá xem mô hình hồi quy tuyến tính có ý nghĩa tổng thể hay không, tức là liệu các biến độc lập có giải thích được biến phụ thuộc hay không. Kiểm định này so sánh phương sai do mô hình giải thích với phương sai còn lại (phần dư), từ đó xác định mức độ phù hợp của mô hình với dữ liệu.

Công thức của thống kê F được tính như sau:

$$F = \frac{MS_{reg}}{MS_{res}} = \frac{SSR/p}{SSE/(n-p-1)}$$

- SSR : Tổng bình phương do hồi quy - phần biến thiên được mô hình giải thích.
- SSE : Tổng bình phương phần dư - phần sai số mô hình không giải thích được.
- p : Số biến độc lập.
- n : Số quan sát (dữ liệu).

Nếu giá trị F đủ lớn và p-value nhỏ so với mức ý nghĩa α (thường $\alpha = 0.05$), ta có thể bác bỏ giả thuyết rỗng và kết luận rằng mô hình có ý nghĩa thống kê.

2.5.5 T-test hồi quy

T-test trong hồi quy tuyến tính được sử dụng để kiểm tra xem từng biến độc lập có ảnh hưởng đáng kể đến biến phụ thuộc hay không.

Công thức thống kê t được tính như sau:

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

- $\hat{\beta}_j$: Hệ số hồi quy ước lượng.
- $SE(\hat{\beta}_j)$: Sai số chuẩn của hệ số.


Nếu giá trị t đủ lớn và p-value nhỏ hơn mức ý nghĩa α (thường là 0.05), ta bác bỏ giả thuyết rỗng và kết luận rằng biến đó có ảnh hưởng có ý nghĩa đến mô hình. Kiểm định T-test giúp xác định những biến nên giữ lại để tối ưu hiệu quả của mô hình hồi quy.

3 Thực nghiệm

3.1 Dữ liệu


Bộ dữ liệu sau thu thập và tiền xử lý bao gồm gần 4000 bản ghi về khách sạn tại các thành phố biển ở Việt Nam, chứa nhiều đặc trưng quan trọng như giá phòng, tiện nghi, khoảng cách, đánh giá và loại hình lưu trú...

Bắt đầu quá trình khám phá và phân tích dữ liệu, nhóm loại bỏ đi thuộc tính Evaluate, vì thuộc tính Evaluate được quyết định bởi thuộc tính target. Tiếp đó, qua quá trình khảo sát phân phối cột Point bằng biểu đồ boxplot và phát hiện nhiều giá trị nằm ngoài phân phối. Tuy nhiên, nhóm không cho rằng đây là các điểm ngoại lai (outlier). Vì những đánh giá điểm thấp 1,2,... của khách hàng là bình thường, thêm vào đó các điểm này xuất hiện với tần suất khá ít nên việc nó nằm ngoài phân phối là điều bình thường.




Hình 4: Biểu đồ boxplot điểm đánh giá của khách hàng

Đánh giá kết quả từ ma trận tương quan cho thấy các thuộc tính như staff, convenient, comfort, worthwhile có mức tương quan rất cao với clean và với nhau. Để tránh trùng lặp thông tin và giảm đa cộng tuyến, nhóm giữ lại duy nhất thuộc tính clean và loại bỏ các cột còn lại.




Hình 5: Ma trận tương quan giữa các thuộc tính

Đối với sự tương quan giữa các thuộc tính với biến mục tiêu, đa số các thuộc tính có độ tương quan với biến target khá thấp, chỉ có thuộc tính clean và destination là nổi trội, đây sẽ là hai yếu tố đóng vai trò quan trọng trong việc mang lại sự hài lòng đến với khách hàng của khách sạn.



Hình 6: Tương quan giữa các thuộc tính với target

Đối với các trường dữ liệu nhị phân, vì đa phần điểm đánh giá đều rơi vào khoảng từ 7 đến 8 điểm (lệch phải), không đáp ứng điều kiện phân phối chuẩn nếu giữ nguyên thang điểm này nên nhóm quyết định bỏ đi dữ liệu có điểm đánh giá bé hơn 6 để phân phối điểm đánh giá trong mỗi nhóm có thể đạt trạng thái gần chuẩn, giúp kết quả kiểm định thống kê đáng tin cậy hơn.



Hình 7: Phân phối điểm đánh giá của thuộc tính sau điều chỉnh

Kết quả phân tích cho thấy một số đặc trưng như view_to_river, eaves, bar, pool và Fitness_center đều có p-value bé hơn mức ý nghĩa 5% do nhóm đặt ra, đồng thời khoảng tin cậy độ khác nhau giữa trung bình 2 nhóm cũng khá lớn. Do đó, các đặc trưng này được giữ lại cho bước xây dựng mô hình, các đặc trưng còn lại bị loại bỏ nhằm giảm nhiễu và tránh mô hình hóa quá mức.

column	T	p-val	CI95%
view_to_beach	1.5522249	0.1207389	[-0.09, 0.01]
view_to_city	1.0642173	0.2870317	[-0.07, 0.02]
view_to_mountain	0.7174972	0.4723133	[0.04, 0.08]
view_to_river	5.7371049	0.0000	[0.12, 0.25]
eaves	9.585953	0.0000	[0.18, 0.28]
pool	7.2627361	0.0000	[0.13, 0.22]
parking	0.113007	0.9104029	[-0.05, 0.06]
airport_shuttle	1.2698464	0.2040735	[-0.32, 0.07]
free_breakfast	1.1260037	0.132428	[-0.03, 0.15]
spa	1.0812167	0.3090139	[-0.1, 0.32]
bar	2.234628	0.0258889	[0.01, 0.15]
Fitness_center	2.2169654	0.0270372	[0.01, 0.14]

Bảng 1: Kết quả kiểm định two-sample t test với trường nhị phân

Đối với các trường phân loại, nhóm tiến hành phân tích các thuộc tính Address, Accommodation Type, Room Level. Kết quả cho ra cả ba đều có p-value bé hơn mức ý nghĩa 5%, cho thấy sự khác biệt giữa các nhóm trong từng thuộc tính.

	SS	F	DF	p-unc
Address	184.1545	38.00656	10	0.00000
Accommodation_Type	78.90567	19.28423	8	0.00000
Room_Level	31.65576	10.08022	6	0.00000

Bảng 2: Kết quả kiểm định ANOVA các trường phân loại phức tạp

Nhóm tiếp tục xác định các cặp nhóm khác nhau trong từng thuộc tính để tiến hành gộp nhằm tinh gọn số lượng nhóm bằng kiểm định hậu nghiệm Post-hoc. Kết quả thu được là số lượng nhóm trong hai trường Accommodation Type, Room Level lần lượt giảm từ 9, 7 còn 4, 3 giúp giảm số lượng nhóm nhưng vẫn giữ được ý nghĩa phân tích,

từ đó giảm độ phức tạp cho mô hình. Riêng đối với trường Address không được kiểm tra do mỗi địa điểm mang tính chất riêng.

column	A	B	p-tukey	combine
Accommodation_Type	biệt thự	căn hộ	0.0000001772	FALSE
Accommodation_Type	biệt thự	khác	0.072744731	TRUE
Accommodation_Type	biệt thự	phòng	0.0000000	FALSE
Accommodation_Type	biệt thự	resort	0.999917026	TRUE
Accommodation_Type	biệt thự	studio	0.005911023	FALSE
Accommodation_Type	biệt thự	suite	2.16662E-05	FALSE
Accommodation_Type	bungalow	suite	0.999999684	TRUE
Accommodation_Type	căn hộ	khác	0.9818331	TRUE
Accommodation_Type	căn hộ	phòng	0.0000000004	FALSE
Accommodation_Type	phòng	resort	0.999999941	TRUE
Room_Level	executive	superior	0.99982666	TRUE
Room_Level	executive	tiêu chuẩn	0.999897834	TRUE
Room_Level	gia đình	khác	0.000175211	FALSE
Room_Level	khác	premium	0.999312465	TRUE
Room_Level	khác	superior	0.001253362	FALSE
Room_Level	khác	tiêu chuẩn	3.06E-08	FALSE

Bảng 3. Kết quả kiểm tra hậu nghiệm và quyết định gom nhóm

3.2 Mô hình

3.2.1 Huấn luyện mô hình

Sau khi hoàn tất quá trình lựa chọn và xử lý các biến đầu vào, nhóm tiến hành xây dựng mô hình hồi quy tuyến tính đa biến nhằm phân tích các yếu tố ảnh hưởng đến sự hài lòng của khách hàng tại khách sạn. Để thực hiện, nhóm sử dụng phương pháp OLS (Ordinary Least Squares – bình phương tối thiểu thông thường), một kỹ thuật phổ biến trong thống kê để ước lượng các hệ số hồi quy tuyến tính. Việc sử dụng OLS cho phép mô hình đồng thời in ra các thống kê quan trọng phục vụ cho việc đánh giá chất lượng mô hình và ý nghĩa của từng biến: bao gồm kiểm định ANOVA hồi quy để đánh giá ý nghĩa tổng thể của mô hình, và kiểm định T-test hồi quy để xác định tầm quan trọng của từng biến độc lập đối với biến phụ thuộc..

3.2.2 Kết quả

Linear Regresion	
MAE	0.2149
R-squared Adjusted	0.771

Bảng 4: Kết quả mô hình trước xử lý thuộc tính

Linear Regresion	
MAE	0.1687
R-squared Adjusted	0.862
F-statistic	360.8
Prob (F-statistic)	0.00

Bảng 5: Kết quả mô hình và kiểm định thống kê ANOVA F-test sau xử lý

Kết quả hồi quy thu được với R-squared Adjusted = 0.862, cho thấy khoảng 86.2% sự biến thiên trong mức độ hài lòng của khách hàng được giải thích bởi các biến đầu vào trong mô hình. Ngoài ra, giá trị sai số trung bình tuyệt đối (MAE) = 0.21489 cho thấy mô hình dự đoán khá chính xác, với sai lệch trung bình giữa giá trị thực và giá trị dự đoán là khá nhỏ. Kết quả của bộ dữ liệu sau khi xử lý và khám phá cho ra kết quả cải thiện hiệu quả của mô hình rõ rệt so với bộ dữ liệu chưa được khám phá và xử lý. Giá trị F-statistic = 360.8 với p-value $\approx$ 0.000 trong phân kiểm định ANOVA cho thấy mô hình có ý nghĩa thống kê tổng thể; tức là tồn tại ít nhất một biến độc lập có tác động đáng kể đến sự hài lòng.

	coef	t	P > t
Dist_DownTown	0.0238	2.546	0.011
Dist_Beach	-0.0001	-0.015	0.988
Price	-0.0073	-0.987	0.324
Stars	-0.0558	-7.025	0.000
Rates_Quantity	0.0157	2.122	0.034
eaves	0.0519	3.693	0.000
pool	-0.0034	-0.217	0.828
bar	-0.0217	-0.956	0.339
Fitness_center	0.0031	0.142	0.887
tourist_spot	0.0684	3.993	0.000
eat_drink_spot	0.0075	1.009	0.313
beachs	-0.0144	-1.61	0.108
clean	0.7164	61.988	0.000
destination	0.2011	16.566	0.000
da nang	-0.036	-0.709	0.479
dao cat ba	0.1535	2.542	0.011
dong hoi	0.058	0.713	0.476
ha long	0.0517	1.029	0.304
hoi an	0.1184	2.411	0.016
mui ne	0.1065	1.654	0.098
nha trang	-0.0697	-1.374	0.17
phu quoc	0.1254	2.202	0.028
quy nhon	0.0663	1.167	0.243
vung tau	-0.0004	-0.008	0.994
Accom_Group_B	-0.0818	-3.649	0.000
Accom_Group_C	0.0331	1.361	0.174
Accom_Group_D	-0.0612	-1.779	0.075

Bảng 6: Kết quả kiểm định thống kê t-test hồi quy

Xét riêng từng biến trong mô hình, kết quả T-test cho thấy một số yếu tố có ảnh hưởng rõ rệt đến điểm hài lòng. Đáng chú ý nhất là biến clean (sạch sẽ) với hệ số lớn dương (coef = 0.7164) và giá trị p gần bằng 0, cho thấy mức độ sạch sẽ của khách sạn có ảnh hưởng mạnh và tích cực đến trải nghiệm của khách hàng. Tương tự, các yếu tố như destination (địa điểm của khách sạn), Distance_to_DownTown (gần trung tâm), tourist_spot (số lượng điểm du lịch) và Rates_Quantity (số lượng đánh giá), eaves (phòng có sân hiên) đều có hệ số dương và p-value nhỏ hơn 0.05, cho thấy tác động tích cực và có ý nghĩa thống kê.

Ngược lại, nhiều yếu tố tương như quan trọng như giá cả (Price), khoảng cách đến biển (Distance_to_Beach), hay sự hiện diện của hồ bơi, quầy bar, phòng tập gym lại không cho thấy ảnh hưởng đáng kể trong mô hình hiện tại. Điều này có thể xuất phát

từ việc những yếu tố đó chưa đủ nổi bật, hoặc do sự kỳ vọng của khách hàng với các tiện nghi này không cao bằng các yếu tố trải nghiệm trực tiếp như vệ sinh, vị trí hay mức độ nổi bật của điểm đến.

Ngoài ra, một số điểm đến như Cát Bà, Hội An, và Phú Quốc cũng cho thấy ảnh hưởng tích cực đến mức độ hài lòng so với địa phương tham chiếu (có thể là Đà Nẵng), trong khi các địa phương khác như Nha Trang, Vũng Tàu hay Quy Nhơn chưa thể hiện rõ sự khác biệt có ý nghĩa thống kê. Một điểm đáng chú ý là biến Stars (số sao) lại có hệ số âm đáng kể (coef = -0.0558, $p < 0.001$), gợi ý rằng khách hàng có thể có kỳ vọng cao hơn ở các khách sạn nhiều sao, dẫn đến cảm giác chưa hài lòng nếu trải nghiệm không tương xứng.

Bên cạnh đó, các loại hình cư trú kiểu phòng, suite cũng thường mang đến sự hài lòng của khách hàng hơn là những loại hình cư trú khác, có lẽ vì chúng đơn giản nên khách hàng không đòi hỏi quá nhiều ở chúng.

Tổng thể, việc sử dụng OLS kết hợp với kiểm định ANOVA và T-test không chỉ giúp nhóm đánh giá chất lượng mô hình một cách toàn diện mà còn chỉ ra rõ những yếu tố nào thực sự tác động đến sự hài lòng của khách hàng trong bối cảnh thực tế. Kết quả mô hình cũng cung cấp cơ sở dữ liệu đáng tin cậy để các nhà quản lý khách sạn đưa ra chiến lược cải thiện dịch vụ một cách có trọng tâm, thay vì tập trung dàn trải vào các yếu tố không có ảnh hưởng đáng kể.

4 Kết luận và hướng phát triển

4.1 Kết luận

Nhóm đã xây dựng bộ dữ liệu về các khách sạn ven biển tại Việt Nam và dựa trên dữ liệu thu thập được, nhóm tiến hành phân tích và khám phá các đặc trưng và kiểm định thống kê nhằm xác định những yếu tố thực sự ảnh hưởng đến mức độ hài lòng của khách hàng. Quá trình kiểm định giúp loại bỏ các biến không mang lại giá trị giải thích, từ đó tập trung vào những yếu tố then chốt còn lại.

Kết quả cho thấy các yếu tố có ảnh hưởng rõ rệt đến sự hài lòng của khách hàng bao gồm: địa điểm khách sạn, khoảng cách đến trung tâm thành phố, số lượng điểm du lịch gần đó, số lượng lượt đánh giá. Ngoài ra, một số địa điểm nổi bật như Cát Bà, Hội An, Phú Quốc; cùng các loại hình lưu trú như phòng tiêu chuẩn hoặc suite thường gắn liền với mức độ hài lòng cao hơn từ phía khách hàng.

Những phát hiện này không chỉ cung cấp góc nhìn dữ liệu rõ ràng về xu hướng và hành vi khách hàng, mà còn là cơ sở tham khảo thiết thực cho các chủ khách sạn, nhà quản lý hoặc nhà đầu tư trong việc đưa ra quyết định chiến lược, tập trung cải thiện các yếu tố cốt lõi, tránh đầu tư dàn trải và không hiệu quả, từ đó nâng cao trải nghiệm khách hàng và tối ưu hóa hiệu quả kinh doanh.

4.2 Ưu và nhược điểm

Quá trình phân tích dữ liệu cho thấy nhiều điểm mạnh nổi bật. Trước hết, bộ dữ liệu được xây dựng có tính phong phú cao, phản ánh sát thực tế hoạt động của các khách sạn ven biển tại Việt Nam. Nhóm đã xử lý tốt yếu tố thời gian khi dữ liệu được thu thập cho các thời điểm đặt phòng trong tương lai gần, giúp đảm bảo độ tin cậy và khả năng ứng dụng thực tiễn của các phân tích. Quy trình tiền xử lý được thực hiện bài bản, từ làm sạch, chuẩn hóa đến trích xuất đặc trưng, giúp dữ liệu đầu vào cho mô hình đạt chất lượng cao. Đặc biệt, việc kết hợp linh hoạt giữa các kỹ thuật phân tích dữ liệu khám phá (EDA), kiểm định thống kê và mô hình học máy đã mang lại cái nhìn toàn diện, giúp xác định rõ các yếu tố then chốt ảnh hưởng đến sự hài lòng của khách hàng, phục vụ hiệu quả cho mục tiêu ứng dụng thực tế.

Tuy vậy, vẫn còn tồn đọng một số hạn chế. Dữ liệu vẫn còn thiếu ở một số trường và chưa bao phủ hết các mùa trong năm, các điểm đến. Nguồn dữ liệu hiện tại cũng chỉ giới hạn từ một nền tảng, chưa phản ánh đầy đủ thị trường lưu trú. Chính vì vậy nên kết luận rút ra có thể chưa phản ánh toàn diện bức tranh thị trường lưu trú.

4.3 Hướng phát triển

Trong thời gian tới, nhóm sẽ mở rộng phạm vi thu thập dữ liệu từ các nền tảng khác như Agoda, Traveloka để tăng tính đại diện và tránh lệ thuộc vào một nguồn duy nhất. Đồng thời, dữ liệu sẽ được bổ sung theo thời gian, bao phủ các mùa trong năm và đa dạng điểm đến nhằm phản ánh đầy đủ hơn xu hướng du lịch và mức độ hài lòng của khách hàng. Những cải tiến này hứa hẹn sẽ nâng cao độ chính xác của mô hình và mở rộng khả năng ứng dụng trong thực tế cho các nhà quản lý, đầu tư và đơn vị nghiên cứu.

Tài liệu tham khảo

1. Selenium with Python. URL: selenium-python.readthedocs.io.
2. Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow - *Aurélien Géron 2nd edition*.
3. J. Pei J. Han and M. Kamber. 2012. Data Mining -*Concept and Techniques 3rd edition*.
4. An Introduction to Statistical Learning: with Applications in Python (ISLP) - Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, Jonathan Taylor.

Công việc	Thành viên thực hiện	Mức độ hoàn thành
- Thu thập dữ liệu	Huỳnh Phát Đạt	100%
- Tiền xử lý dữ liệu	Bùi Quốc Bảo	100%
- Đánh giá dữ liệu	Lê Minh Khôi	100%
- Khám phá và phân tích dữ liệu - Khảo sát. - Viết báo cáo. - Làm slide thuyết trình. - Xây dựng và đánh giá mô hình.	Lê Minh Khôi Bùi Quốc Bảo Huỳnh Phát Đạt	100%

Bảng 7: Phân công công việc