

Xây dựng bộ dữ liệu và ứng dụng học máy trong dự đoán giá phòng khách sạn du lịch biển ở Việt Nam

Bùi Quốc Bảo^{1,2,3}, Lê Minh Khôi^{1,2,3}, Huỳnh Phát Đạt^{1,2,3}, Nguyễn Gia Tuấn Anh^{1,2,4}, Trần Quốc Khánh^{1,2,4}

¹ Khoa Khoa học và Kỹ thuật thông tin

² Trường Đại học Công Nghệ Thông Tin

³{23520091, 23520767, 24520270} @gm.uit.edu.vn

⁴{anhngt, khanhtq} @uit.edu.vn

Tóm tắt

Đồ án tập trung vào việc thu thập và tiền xử lý dữ liệu khách sạn ven biển tại các thành phố du lịch và huyện đảo nổi tiếng ở Việt Nam, nhằm xây dựng một bộ dữ liệu có cấu trúc, sạch và sẵn sàng phục vụ mô hình dự đoán giá. Dữ liệu được thu thập từ Booking.com bằng phương pháp web scraping sử dụng Selenium trong Python, sau đó trải qua các bước xử lý để chuyển đổi các thông tin phi cấu trúc thành dữ liệu có thể phân tích. Hai mô hình học máy được triển khai là Linear Regression, Lasso Regression, Ridge Regression và Random Forest Regressor, nhằm dự đoán giá phòng từ các đặc trưng như vị trí, tiện nghi, số sao, điểm đánh giá... Mô hình được đánh giá qua các độ đo MAE và R2, đồng thời thực hiện tối ưu siêu tham số bằng Grid Search kết hợp Cross-Validation để nâng cao hiệu suất. Kết quả cho thấy Random Forest Regressor hoạt động tốt hơn với độ chính xác cao hơn, khẳng định chất lượng và tiềm năng ứng dụng của bộ dữ liệu. Qua đó, đề tài khẳng định việc đầu tư vào khâu xử lý dữ liệu là bước quan trọng để đảm bảo chất lượng cho các ứng dụng học máy phía sau. Ngoài ra, bộ dữ liệu còn có tiềm năng phục vụ cho nhiều bài toán khác như phân cụm khách sạn; hệ thống gợi ý hoặc phân tích xu hướng thị trường du lịch...

1 Giới thiệu

Trong thời đại du lịch và công nghệ số phát triển mạnh mẽ, việc ra quyết định đặt phòng khách sạn không còn dựa vào cảm tính mà ngày càng cần đến dữ liệu. Một trong những yếu tố ảnh hưởng lớn đến hành vi khách hàng là giá phòng, vốn biến động theo vị trí, thời điểm, tiện nghi, số sao và các yếu tố khác.

Việc dự đoán giá phòng khách sạn mang lại nhiều ứng dụng thực tiễn. Du khách có thể lên kế hoạch chi tiêu hợp lý hơn; các nền tảng đặt phòng có thể dùng gợi ý phòng phù hợp; chủ khách sạn có thể áp dụng để đưa ra mức giá cạnh tranh theo thời gian thực; các nhà đầu tư, phân tích thị trường có thể theo dõi xu hướng giá nhằm hỗ trợ quyết định kinh doanh;...

Xuất phát từ nhu cầu đó, nhóm thực hiện việc thu thập và tiền xử lý dữ liệu khách sạn ở các địa điểm du lịch biển nổi tiếng tại Việt Nam từ Booking.com bằng công cụ Selenium. Các thông tin về khách sạn được tự động trích xuất và xử lý với mục tiêu là xây dựng một bộ dữ liệu sạch, có cấu trúc và giàu đặc trưng có thể phục vụ cho các mục đích nghiên cứu, phân tích. Trên

cơ sở đó, nhóm tiến hành xây dựng mô hình máy học dự đoán giá phòng dựa trên các đặc trưng đầu vào.

2 Dữ liệu

2.1 Khảo sát

Trước khi tiến hành thu thập, nhóm đã tham khảo một số bộ dữ liệu và dự án về khách sạn trên Kaggle và GitHub như TBO Hotels, Airbnb Price Prediction, Hotel Booking Demand,... Qua đó, rút ra được các đặc trưng cơ bản cần thiết cho bài toán dự đoán giá phòng như tên khách sạn, vị trí, loại hình lưu trú, số sao, giá, đánh giá tổng thể và tiện nghi. Tuy nhiên sau khi xem xét, các bộ dữ liệu này thường thiếu nhiều yếu tố quan trọng khác như khoảng cách địa lý, loại view, tiện ích như hồ bơi, đưa đón sân bay, đánh giá chi tiết theo từng khía cạnh. Ngoài ra, chúng cũng chưa gắn với bối cảnh đặt phòng thực tế như ngày check-in, check-out hay số người lưu trú.

Sau khi thực hiện khảo sát, nhóm tiến hành xây dựng hệ thống thu thập dữ liệu tự động với mục tiêu bộ dữ liệu có đủ các đặc trưng cơ bản cũng như chi tiết như đã nêu. Các thông tin chi tiết này sẽ là yếu tố then chốt góp phần mang đến một bộ dữ liệu phong phú, phản ánh được nhiều khía cạnh ảnh hưởng đến giá khách sạn.

2.2 Thu thập dữ liệu

Để xây dựng bộ dữ liệu phục vụ bài toán dự đoán giá phòng khách sạn ven biển tại Việt Nam, nhóm tiến hành thu thập dữ liệu từ trang web Booking.com – nền tảng đặt phòng phổ biến, có giao diện hiện đại và lượng thông tin khách sạn phong phú. Do trang web này có cấu trúc nội dung được tải động, nhóm sử dụng phương pháp web scraping động với thư viện Selenium trong môi trường Python để thực hiện thu thập dữ liệu.

2.2.1 Công cụ và thư viện sử dụng

Quá trình thu thập dữ liệu được nhóm thực hiện trong môi trường Python, sử dụng nhiều thư viện hỗ trợ. Selenium là thư viện chính, cho phép điều khiển trình duyệt Chrome tự động để truy cập trang, cuộn, nhấn nút và trích xuất nội dung đã render từ Booking.com, vì vốn là một trang tải động nên không thể dùng các thư viện crawl tĩnh. Ngoài ra, nhóm còn sử dụng Pandas để lưu


trữ và xử lý dữ liệu, NumPy và time.sleep để tạo độ trễ ngẫu nhiên mô phỏng hành vi người dùng, datetime để xử lý ngày tháng, os để thao tác file, và urllib.parse để phân tích thông tin từ URL.

2.2.2 Quy trình thu thập

Quy trình thu thập dữ liệu bắt đầu bằng việc khởi tạo trình duyệt Chrome thông qua Selenium và tạo danh sách các liên kết URL truy vấn đến trang Booking.com, với các tổ hợp bao gồm ngày check-in, check-out, số lượng người lớn và trẻ em. Các tổ hợp này được sinh tự động nhằm mô phỏng đa dạng tình huống đặt phòng thực tế. Đồng thời, nhóm cũng xây dựng cơ chế ghi nhận ngày thực hiện crawl, giúp theo dõi thời điểm dữ liệu được thu thập để phục vụ cho việc đánh giá tính thời điểm và phân tích theo ngữ cảnh trong các bước xử lý tiếp theo.


Hệ thống truy cập Booking.com, lọc các điểm du lịch biển bằng cách nhấn vào nút “Biển”, sau đó thu thập danh sách liên kết đến từng địa điểm như thành phố hoặc huyện đảo.

Với mỗi địa điểm, hệ thống cuộn trang để tải toàn bộ danh sách khách sạn và trích xuất các thông tin cơ bản như tên, địa chỉ, giá phòng, khoảng cách, số sao, đánh giá,... đồng thời lấy link truy cập trang chi tiết của từng khách sạn.



Trang danh sách thực hiện thu thập các thông tin cơ bản

Tiếp theo, hệ thống lần lượt truy cập vào từng khách sạn để lấy thêm các đặc trưng chi tiết như loại view, tiện nghi nổi bật, khoảng cách đến sân bay, số lượng địa điểm gần đó và đánh giá theo từng khía cạnh như sạch sẽ, tiện nghi, vị trí, đáng tiền,...



Thông tin chi tiết thu thập trong từng trang khách sạn

Trong toàn bộ quá trình, nhóm áp dụng nhiều cơ chế mô phỏng hành vi người dùng như cuộn trang nhẹ (scroll), nhấn nút, và chèn độ trễ ngẫu nhiên giữa các thao tác nhằm tránh bị phát hiện là bot. Đồng thời, nhóm cũng xây dựng cơ chế xử lý lỗi và bị chặn bot hiệu quả: nếu trang không tải được hoặc gặp sự cố, hệ thống sẽ tự động reset trình duyệt và thử lại thao tác tối đa 3-4 lần, đảm bảo quá trình thu thập không bị gián đoạn và dữ liệu không bị bỏ sót. Ngoài ra còn có cơ chế lưu an toàn, sau mỗi lượt thu thập thành công các thông tin sẽ được lưu ra tệp tạm thời. Điều này giúp tránh mất thông tin không đáng có bởi những sự cố khách quan.

Cuối cùng, dữ liệu cơ bản và chi tiết về khách sạn được gộp lại thành một bảng duy nhất, kèm theo các thông tin truy vấn đầu vào. Đây là tập dữ liệu thô, tương ứng với tầng Bronze trong kiến trúc dữ liệu Medallion, làm đầu vào cho bước tiền xử lý tiếp theo.

2.3 Đánh giá dữ liệu sau thu thập

Tập dữ liệu sau khi thu thập ở tầng Bronze gồm gần 300.000 bản ghi về khách sạn tại các thành phố biển ở Việt Nam, chứa nhiều đặc trưng quan trọng như giá phòng, tiện nghi, khoảng cách, đánh giá và loại hình lưu trú. Về tính chính xác, dữ liệu được thu thập trong thời gian gần hiện tại nên phản ánh khá sát thực tế. Tuy nhiên, do đặc thù giá phòng biến động liên tục theo tình trạng phòng, sự kiện hay mùa du lịch, nên độ chính xác tuyệt đối tại thời điểm sử dụng không được đảm bảo. Việc ghi rõ ngày thu thập cho từng bản ghi là một điểm mạnh, giúp người dùng đánh giá được mức độ lệch thời gian và lọc dữ liệu phù hợp với mục đích phân tích.

Xét về tính đầy đủ, một số trường dữ liệu như khoảng cách đến biển hay số sao bị thiếu với tỷ lệ cao (gần 40%). Dữ liệu hiện chỉ bao phủ vài tháng và chỉ thu thập từ nền tảng Booking.com, nên chưa đủ để phản ánh đầy đủ sự thay đổi giá theo thời gian hay toàn cảnh thị trường lưu trú. Tuy vậy, sự đa dạng của các trường dữ liệu thu thập được đã giúp tạo nên một nền tảng thông tin phong phú, phục vụ tốt cho các bước phân tích. Về tính nhất quán, dữ liệu còn nhiều biểu diễn không đồng nhất: cùng một loại thông tin có thể được ghi bằng chữ hoa, thường, tiếng Anh hoặc tiếng Việt, trong khi các trường định lượng như giá, thuế, khoảng

cách lại lưu dưới dạng chuỗi văn bản có kèm ký tự, gây khó khăn khi xử lý.

Tuy nhiên, dữ liệu có tính cập nhật tốt, được thu thập liên tục theo ngày, đảm bảo tính thời sự cho các bài toán dự đoán gần thực tế. Dữ liệu cũng được lấy từ Booking.com, nền tảng uy tín và có cơ chế kiểm duyệt rõ ràng, đảm bảo tính tin cậy tương đối cao. Về mặt dễ hiểu, tên các trường rõ ràng, dễ tiếp cận và phản ánh đúng nội dung. Tập dữ liệu không chứa bất kỳ thông tin định danh cá nhân nào, đảm bảo tính bảo mật và có thể sử dụng an toàn trong môi trường học thuật.

Tuy vậy, cần lưu ý đến khả năng thiên kiến trong dữ liệu, đặc biệt là các trường đánh giá của khách hàng, vốn thường đến từ những người có trải nghiệm quá tốt hoặc quá tệ. Thêm vào đó, việc chỉ thu thập từ một nền tảng có thể làm giảm tính đại diện cho toàn bộ thị trường lưu trú. Cuối cùng, dữ liệu hiện tại vẫn còn nhiều điểm chưa được chuẩn hóa về mặt định dạng và cấu trúc, do đó cần được xử lý kỹ lưỡng trước khi đưa vào các bước phân tích sâu hơn hoặc huấn luyện mô hình học máy.

2.4 Tiền xử lý dữ liệu

Giai đoạn tiền xử lý dữ liệu là bước quan trọng, giúp chuyển đổi dữ liệu thô ban đầu thành dữ liệu có cấu trúc và chất lượng phù hợp cho các bước phân tích và mô hình hóa. Trong kiến trúc phân tầng dữ liệu mà nhóm áp dụng, giai đoạn này đánh dấu sự chuyển tiếp từ tầng Bronze (dữ liệu nguyên bản) sang tầng Silver (dữ liệu đã chuẩn hóa kỹ thuật), với mục tiêu đảm bảo tính đầy đủ, nhất quán và hợp lệ của dữ liệu trước khi thực hiện các bước khám phá, chọn lọc đặc trưng và huấn luyện mô hình ở tầng Gold.

Các thao tác trong giai đoạn này bao gồm việc chuẩn hóa định dạng chuỗi, làm sạch dữ liệu nhiễu, xử lý dữ liệu thiếu, chuyển đổi kiểu dữ liệu, bóc tách các đặc trưng từ chuỗi văn bản phức tạp, quy đổi đơn vị đo lường, xử lý các giá trị định lượng bị sai định dạng và mã hóa các biến phân loại. Ngoài ra, nhóm cũng tiến hành chuẩn hóa các đánh giá người dùng theo thang điểm định lượng, xử lý các cột boolean. Qua đó, dữ liệu sau xử lý có định dạng thống nhất, sạch, đầy đủ, sẵn sàng cho các bước khám phá và trích chọn đặc trưng trong các phần tiếp theo của đồ án.

2.4.1 Xử lý tổng thể

Sau khi hoàn tất bước thu thập, nhóm đã tiến hành xử lý tổng thể dữ liệu để loại bỏ nhiễu và đảm bảo tính toàn vẹn. Các dòng trống hoàn toàn được loại bỏ, các chuỗi văn bản được chuẩn hóa bằng cách xóa khoảng trắng dư và thay thế các ô chứa khoảng trắng bằng giá trị thiếu (NaN). Tiếp theo, nhóm thống kê tỷ lệ thiếu trên từng cột để xác định mức độ thiếu hụt. Với những trường có tỷ lệ thiếu thấp (dưới 5%), nhóm quyết định loại bỏ các dòng chứa giá trị thiếu nhằm đảm bảo tính sạch sẽ của dữ liệu mà vẫn giữ được phần lớn thông tin.

Sau bước này, dữ liệu được kiểm tra lại lần cuối để đảm bảo tất cả giá trị thiếu đã được xử lý đồng bộ.

2.4.2 Chuẩn hóa dữ liệu

Ở bước này, nhóm thực hiện chuẩn hóa dữ liệu để đồng nhất định dạng và đơn vị, hỗ trợ tốt hơn cho quá trình phân tích và mô hình hóa. Đầu tiên là cột địa chỉ (Address), được xử lý để trích xuất tên địa điểm chính (thành phố hoặc khu du lịch) bằng cách chuẩn hóa biến thể chính tả và giữ lại phần địa danh cốt lõi. Các trường khoảng cách như đến trung tâm, sân bay và biển cũng được làm sạch, quy đổi thống nhất về đơn vị kilomet. Những mô tả định tính như "gần trung tâm", "giáp biển" được gán giá trị 0, trong khi các giá trị định lượng được xử lý bằng biểu thức chính quy. Trường giá phòng (price) và thuế (taxes) được trích xuất số, loại bỏ ký hiệu tiền tệ và định dạng về kiểu số thực. Với các mô tả như "đã bao gồm thuế", hệ thống tự động gán bằng 0. Các trường đánh giá văn bản như "Tốt", "Rất tốt", "Tuyệt vời" được mã hóa theo thứ tự bằng Ordinal Encoding. Các trường định lượng khác như rates_quantity, point, staff, clean,... cũng được xử lý để chuẩn hóa dấu thập phân và chuyển về định dạng số thực. Về xử lý ngày tháng, nhóm chuyển cột checkin, checkout về kiểu datetime, tách thành day, month, xác định ngày cuối tuần (is_weekend) và gán nhãn cho các ngày lễ, sự kiện đặc biệt (is_special_day). Các khách sạn không có thông tin số sao (stars) được gán mặc định là 0.

2.4.3 Trích xuất đặc trưng

Cuối cùng, nhóm tiến hành trích xuất đặc trưng từ các trường dạng văn bản phức tạp. Đối với trường kind (loại hình lưu trú), dữ liệu được chuẩn hóa ngôn ngữ và từ khóa, sau đó trích xuất thành hai trường mới là Accommodation_Type (phòng, căn hộ, biệt thự,...) và Room_Level (tiêu chuẩn, deluxe,...), đồng thời bóc tách số giường hoặc số phòng nếu có thể. Các thông tin này được lưu vào cột riêng, còn cột kind gốc bị loại bỏ để tránh dư thừa. Trường name (tên khách sạn) cũng được làm sạch bằng cách chuyển về chữ thường, loại bỏ ký tự đặc biệt, từ dừng, tên địa phương trùng lặp và giữ lại phần tên chính. Việc này giúp dữ liệu trở nên rõ ràng, đồng nhất và thuận tiện hơn cho các bước phân tích và huấn luyện mô hình học máy.


Sau khi hoàn tất các bước tiền xử lý, tập dữ liệu đã được làm sạch, chuẩn hóa và trích xuất đầy đủ các đặc trưng quan trọng, đạt yêu cầu của tầng Silver trong kiến trúc dữ liệu Medallion. Tại tầng này, dữ liệu không còn nhiễu, các định dạng đã đồng nhất, giá trị thiếu được xử lý hợp lý và các trường thông tin phức tạp đã được tách riêng, giúp tăng tính rõ ràng và khai thác được giá trị tiềm ẩn từ dữ liệu thô. Nhờ đó, tập dữ liệu hiện đã sẵn sàng để sử dụng trong các bước phân tích thống kê,

khám phá dữ liệu (EDA) và xây dựng mô hình học máy một cách hiệu quả và chính xác hơn.

2.5 Khám phá và phân tích dữ liệu

Sau khi hoàn tất giai đoạn tiền xử lý và lưu trữ dữ liệu ở tầng Silver, nhóm tiến hành bước EDA nhằm khám phá, hiểu rõ đặc trưng dữ liệu và chuẩn bị cho việc xây dựng tập dữ liệu đầu vào cuối cùng cho mô hình, tức tầng Gold. Quá trình này không chỉ giúp phát hiện các điểm bất thường, xu hướng ẩn và mối liên hệ giữa các biến, mà còn góp phần tinh gọn và lựa chọn các đặc trưng có giá trị.


Nhóm bắt đầu bằng việc kết hợp giá phòng và thuế thành một biến duy nhất, sau đó khảo sát phân phối giá bằng biểu đồ boxplot và phát hiện nhiều giá trị ngoại lai. Để đảm bảo độ chính xác trong phân tích, dữ liệu được chia thành hai tập: một tập chứa các dữ liệu khách sạn có giá nằm ngoài phân vị thứ ba của khoảng tứ phân vị mở rộng (gọi là tập bất thường), và một tập còn lại đại diện cho phần dữ liệu ổn định. Nhóm tập trung phân tích trên tập ổn định và loại bỏ tập bất thường để giảm nhiễu, đồng thời khảo sát sự khác biệt về giá theo từng đặc trưng để xác định mức độ ảnh hưởng của các yếu tố này.



Biểu đồ boxplot tổng giá phòng và thuế phí

2.5.1 Sự tương quan của các trường dữ liệu

Trước tiên là phân tích sự tương quan của các trường dữ liệu đối với nhau và đối với giá khách sạn, nhóm tập trung vào các thuộc tính định lượng như khoảng cách, đánh giá, số sao, số lượng địa điểm xung quanh, và các đặc điểm của khách lưu trú. Qua ma trận tương quan, nhóm nhận thấy các thuộc tính đánh giá chi tiết như *evaluate*, *staff*, *convenient*, *clean*, *comfort*, *worthwhile* có mức tương quan rất cao với tổng điểm *Point*, điều này có thể là do tổng điểm *Point* được suy ra từ trung bình cộng các thuộc tính đánh giá chi tiết ấy. Để tránh trùng lặp thông tin và giảm đa cộng tuyến, nhóm quyết định giữ lại duy nhất thuộc tính *Point* và loại bỏ các trường cột thuộc tính điểm đánh giá chi tiết khách sạn còn lại.



Ma trận tương quan giữa các thuộc tính

2.5.2 Phân tích các trường dữ liệu nhị phân

Trong bước phân tích này, nhóm tập trung khảo sát mức độ ảnh hưởng của các trường dữ liệu dạng nhị phân như *pool*, *view_to_beach*, *airport_shuttle*... đến giá phòng. Mục tiêu là đánh giá xem sự có hay không của một tiện ích cụ thể có dẫn đến chênh lệch đáng kể về giá hay không, qua đó phục vụ việc lựa chọn đặc trưng đầu vào cho mô hình học máy.

Để đánh giá, nhóm áp dụng kiểm định t hai mẫu độc lập (two sample t-test). Đây là một phương pháp thống kê được sử dụng để kiểm tra xem trung bình của hai nhóm độc lập có khác biệt một cách có ý nghĩa hay không. Nói cách khác, t-test trả lời cho câu hỏi “liệu sự khác biệt trung bình quan sát được giữa hai nhóm là thực sự tồn tại, hay chỉ là do ngẫu nhiên trong quá trình lấy mẫu”.

Công thức tổng quát của kiểm định t hai mẫu độc lập là:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Trong đó:

- $\bar{X}_1, \bar{X}_2$: trung bình mẫu của hai nhóm.
- s_1^2, s_2^2 : phương sai mẫu.
- n_1, n_2 : kích thước mẫu tương ứng.

Từ kiểm định t, nhóm tính khoảng tin cậy 95% cho hiệu trung bình giữa hai nhóm để có cái nhìn trực quan và đáng tin cậy hơn về mức độ chênh lệch giá. Khoảng tin cậy là một khoảng giá trị được xây dựng từ dữ liệu mẫu, giúp ước lượng phạm vi mà giá trị trung bình thực

sự của tổng thể có khả năng nằm trong đó, với xác suất 95%.

Công thức tổng quát của khoảng tin cậy cho hiệu trung bình là:

$$CI = (\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Trong đó:

- $(\bar{X}_1 - \bar{X}_2)$: hiệu trung bình giữa hai nhóm.
- $z_{\alpha/2}$: giá trị tới hạn từ phân phối chuẩn.
- Biểu thức dưới căn là sai số chuẩn của hiệu trung bình.

Thông thường, nếu khoảng tin cậy không bao gồm giá trị 0, ta có thể kết luận rằng sự khác biệt giữa hai nhóm là có ý nghĩa thống kê. Tuy nhiên, nhóm không dừng lại ở mức đánh giá thống kê mà còn đặt ra một tiêu chí thực tiễn cụ thể. Theo đó, chỉ những đặc trưng nhị phân có cả hai đầu mút của khoảng tin cậy đều lớn hơn 100.000 VND mới được xem là có ảnh hưởng thực sự đến giá phòng. Đây là cách nhóm đánh giá ý nghĩa thực tiễn, đảm bảo rằng sự khác biệt không chỉ có ý nghĩa về mặt thống kê mà còn đủ lớn để tạo ảnh hưởng đáng kể trong bối cảnh kinh doanh.

	two sample t - test (p-value)	Mean Difference	95% CI
view_to_beach	1.3E-25	49639.367	40077.1043; 59201.6297
view_to_city	0.0E+00	419870.7648	411016.6803; 428724.8493
view_to_mountain	0.0E+00	347469.3621	337194.5652; 357744.1589
view_to_river	2.2E-36	79161.1526	66948.9828; 91373.3224
eaves	1.2E-94	101913.3333	92339.7217; 111486.9448
pool	0.0E+00	820118.4056	810923.1673; 829313.6438
parking	8.5E-36	63971.2407	53895.2757; 74047.2056
is_weekend	1.9E-176	143075.882	133326.2570; 152825.5070
is_special_day	1.9E-176	95193.5018	67238.2139; 123148.7898
airport_shuttle	5.8E-01	2952.2041	-7617.1204; 13521.5286


Kết quả kiểm định

Kết quả phân tích cho thấy một số đặc trưng như view_to_mountain, view_to_city, pool và is_weekend đều có khoảng tin cậy nằm hoàn toàn phía trên mức 100.000 VND, đồng nghĩa với việc không chỉ có khác biệt rõ ràng giữa hai nhóm, mà chênh lệch này còn đủ lớn để được coi là quan trọng trong thực tế. Do đó, các đặc trưng này được giữ lại cho bước xây dựng mô hình, trong khi các đặc trưng còn lại bị loại bỏ nhằm giảm nhiễu và tránh mô hình hóa quá mức.

2.5.3 Khám phá thứ bậc các trường phân loại

Các đặc trưng có bản chất thứ bậc như Accommodation_Type và Room_Level được mã hóa theo thứ tự dựa trên mức giá đại diện của từng nhóm. Cụ thể, nhóm sử dụng giá trị từ phân vị thứ ba, tức mức giá thuộc nhóm 25% cao nhất để làm căn cứ xếp hạng thứ tự. Cách làm này giúp phản ánh tương đối mức độ “cao cấp” của từng loại hình lưu trú hay hạng phòng

một cách khách quan, dựa trên dữ liệu thực tế thay vì giả định chủ quan.



Biểu đồ boxplot phân bố giá theo từng loại hình cư trú

Đối với đặc trưng danh mục không có thứ bậc Room/Bed Quantity, nhóm sử dụng phương pháp one-hot encoding để chuyển đổi thành dạng nhị phân. Cách mã hóa này đảm bảo rằng mô hình học máy có thể xử lý các giá trị phân loại này một cách rõ ràng, đồng thời tránh làm mất thông tin phân biệt giữa các nhóm giá trị khác nhau.

Sau khi đã thực hiện việc chọn lọc đặc trưng và encode, nhóm một lần nữa tiến hành kiểm tra chỉ số VIF (Variance Inflation Vector) – hệ số phóng đại phương sai với mục tiêu kiểm tra hiện tượng đa cộng tuyến. Từ đó, loại bỏ các biến độc lập có chỉ số VIF >10 để đảm bảo không còn xảy ra hiện tượng đa cộng tuyến.

Riêng với trường name, nhóm áp dụng TF-IDF để trích xuất các từ khóa quan trọng mang ý nghĩa phân biệt trong tên khách sạn, hạn chế còn 100 đặc trưng đầu ra để tối ưu chi phí tính toán. Các đặc trưng này sau đó được ghép với tập dữ liệu hiện tại, tạo thành phiên bản đầy đủ nhất của dữ liệu tầng Gold.

2.6 Tổng kết

Quá trình EDA không chỉ giúp nhóm hiểu rõ đặc điểm nội tại của dữ liệu mà còn đóng vai trò quan trọng trong việc định hình lại cấu trúc và lựa chọn các đặc trưng phù hợp nhất cho mô hình dự đoán giá khách sạn. Thông qua việc phân tích mối quan hệ giữa các biến, đánh giá ý nghĩa thống kê và thực tiễn của từng đặc trưng, nhóm đã loại bỏ được các yếu tố dư thừa và giữ lại những thông tin mang giá trị phân tích cao. Nhờ đó, tập dữ liệu đầu vào trở nên tinh gọn, giàu thông tin và mang tính mô hình hóa cao. Quan trọng hơn, sau bước EDA, dữ liệu đã đạt mức độ chuẩn hóa và tổ chức đầy đủ để chuyển sang tầng Gold trong kiến trúc phân tầng dữ liệu, sẵn sàng phục vụ cho các thuật toán học máy ở các bước tiếp theo.

3 Phương pháp máy học

3.1 Mô hình

3.1.1 Linear Regression (Hồi quy tuyến tính)

Linear Regression là một trong những mô hình cơ bản nhất trong học máy và thống kê, được sử dụng để mô hình hóa mối quan hệ tuyến tính giữa các biến đầu vào (các đặc trưng) và biến đầu ra (giá khách sạn). Mô hình tìm ra một đường thẳng (trong không gian nhiều chiều) sao cho sai số giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất. Mô hình học một hàm số tuyến tính dưới dạng:

$$y = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

- y : giá khách sạn dự đoán
- x_i : các đặc trưng đầu vào như số sao, vị trí, điểm đánh giá, tiện nghi,...
- w_i : hệ số của từng đặc trưng.
- b : hệ số chệch (bias)

Mô hình này phù hợp với dữ liệu có mối quan hệ tuyến tính rõ ràng và ít nhiễu.

3.1.2 Ridge Regression (Hồi quy Ridge)

Ridge Regression là một mở rộng của Linear Regression, được thiết kế để khắc phục vấn đề đa cộng tuyến, tức là khi các đặc trưng đầu vào có tương quan mạnh với nhau, dẫn đến hệ số w_i dao động lớn và không ổn định.

Ridge thêm vào hàm mất mát một thành phần phạt L2, là tổng bình phương các hệ số:

$$\text{Loss} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum w_i^2$$

- λ : hệ số điều chỉnh mức độ phạt, giúp kiểm soát độ lớn của các hệ số.
- Khi $\lambda = 0$, mô hình trở về Linear Regression.

Mục tiêu là giảm overfitting, tăng khả năng khái quát hóa khi áp dụng cho dữ liệu mới.

3.1.3 Lasso Regression (Hồi quy Lasso)

Lasso Regression tương tự như Ridge, nhưng thay vì phạt bình phương (L2), nó sử dụng phạt L1, tức là tổng trị tuyệt đối của các hệ số:

$$\text{Loss} = \sum (y_i - \hat{y}_i)^2 + \lambda \sum |w_i|$$

Điểm đặc biệt của Lasso là nó có khả năng chọn lọc đặc trưng tự động, đẩy một số hệ số về 0, loại bỏ các đặc trưng không quan trọng. Đây là điểm mạnh khi làm việc với tập dữ liệu có nhiều đặc trưng, giúp mô hình đơn giản hơn và dễ giải thích hơn.

3.1.4 Random Forest Regressor

Random Forest là một mô hình ensemble learning dựa trên tập hợp nhiều cây quyết định (decision trees). Mỗi cây trong rừng được huấn luyện trên một tập con ngẫu nhiên của dữ liệu (bagging) và chọn một tập con ngẫu nhiên các đặc trưng tại mỗi nút chia. Kết quả dự đoán cuối cùng là trung bình dự đoán của tất cả các cây

Random Forest thường hoạt động rất tốt trong các bài toán thực tế có dữ liệu phức tạp và không tuyến tính, như bài toán dự đoán giá khách sạn mà nhóm đang thực hiện.

3.2 Độ đo

3.2.1 Mean Absolutely Error (MAE)

MAE đo mức độ sai lệch trung bình giữa giá trị dự đoán và giá trị thực tế, bằng cách lấy trị tuyệt đối sai số cho từng mẫu và tính trung bình:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

MAE dễ hiểu, dễ diễn giải trong bài toán dự đoán giá khách sạn mà nhóm thực hiện. Không bị ảnh hưởng quá mức bởi các ngoại lệ (outliers) như MSE. Đơn vị của MAE giống với đơn vị biến mục tiêu (vd: ngàn đồng, triệu đồng).

3.2.2 Adjusted R-squared (R^2 hiệu chỉnh)

Adjusted R-squared là phiên bản đã điều chỉnh của R^2 , giúp đánh giá mức độ phù hợp của mô hình hồi quy với dữ liệu, đồng thời có tính đến số lượng biến độc lập trong mô hình:

$$R_{adj}^2 = 1 - (1 - R^2) \cdot \frac{n - 1}{n - p - 1}$$

- n : Số lượng mẫu
- p : Số lượng biến độc lập
- R^2 : Hệ số xác định thông thường (R-squared) - cho biết mô hình giải thích được bao nhiêu phần trăm phương sai của dữ liệu.

R_{adj}^2 tăng khi thêm biến có ý nghĩa thống kê. R_{adj}^2 giảm nếu thêm biến không mang lại cải thiện thực sự. Do đó, nó giúp tránh hiện tượng overfitting và phản ánh chính xác hơn hiệu quả của mô hình.

3.3 Kiểm định thống kê ANOVA F-test

ANOVA F-test (Analysis of Variance for Regression) là một phương pháp kiểm định thống kê nhằm đánh giá xem mô hình hồi quy tuyến tính có ý nghĩa tổng thể hay không, tức là liệu các biến độc lập có giải thích được biến phụ thuộc hay không. Kiểm định này so sánh phương sai do mô hình giải thích với phương sai còn lại (phần dư), từ đó xác định mức độ phù hợp của mô hình với dữ liệu.

Công thức của thống kê F được tính như sau:

$$F = \frac{MS_{reg}}{MS_{res}} = \frac{SSR/p}{SSE/(n - p - 1)}$$

- SSR : Tổng bình phương do hồi quy - phần biến thiên được mô hình giải thích.

- SSE : Tổng bình phương phần dư - phần sai số mô hình không giải thích được.
- p : Số biến độc lập.
- n : Số quan sát (dữ liệu).

Nếu giá trị F đủ lớn và p -value nhỏ so với mức ý nghĩa α (thường $\alpha = 0.05$), ta có thể bác bỏ giả thuyết rỗng và kết luận rằng mô hình có ý nghĩa thống kê.

3.4 Huấn luyện mô hình và kết quả

3.4.1 Huấn luyện mô hình

Sau khi hoàn tất các bước tiền xử lý, phân tích và đánh giá dữ liệu, nhóm tiến hành huấn luyện và kiểm thử mô hình bằng bốn thuật toán học máy đã nêu ở trên. Quá trình đánh giá được thực hiện thông qua kỹ thuật Cross-Validation kết hợp với phương pháp tìm kiếm siêu tham số tối ưu bằng GridSearchCV nhằm đảm bảo độ chính xác và khả năng tổng quát hóa của mô hình.

Với ba mô hình hồi quy tuyến tính là Linear Regression, Ridge Regression và Lasso Regression, nhóm thực hiện chuẩn hóa dữ liệu đầu vào (feature scaling) bằng StandardScaler nhằm đảm bảo tính công bằng giữa các thuộc tính, đặc biệt là các đặc trưng nhị phân vốn chiếm tỷ trọng lớn trong tập dữ liệu. Việc chuẩn hóa này giúp các thuật toán tuyến tính hoạt động ổn định hơn và tránh việc bị chi phối bởi các đặc trưng có giá trị tuyệt đối lớn.

3.4.2 Kết quả

	Train	Test	Test (tunned model)
Linear Regression	539331.07	537773.93	537773.93
Lasso Regression	539366.15	537773.92	537773.91
Ridge Regression	539337.51	537779.35	537772.39
Random Forest Regressor	104536.67	95738.61	95841.16

Kết quả trên độ đo MAE

	Train	Test	Test (tunned model)
Linear Regression	0.54877	0.55327	0.55327
Lasso Regression	0.54876	0.55326	0.55327
Ridge Regression	0.54877	0.55325	0.55327
Random Forest Regressor	0.95419	0.95869	0.95846

Kết quả trên độ đo R^2 Adjusted

Cơ sở để triển khai các mô hình hồi quy nâng cao như Ridge và Lasso đến từ việc kiểm định ý nghĩa thống kê của mô hình Linear Regression:

	OLS
F-statistic	1567
Prob (F-statistic)	0.00

Kết quả kiểm định thống kê F-test

Cụ thể, nhóm đã sử dụng phương pháp phân tích phương sai (ANOVA) cho hồi quy tuyến tính thông qua ANOVA F-test với thư viện statsmodels.OLS và kết quả cho thấy F-statistic rất lớn và p -value ≈ 0.00 , khẳng định mô hình có ý nghĩa thống kê và tồn tại mối quan hệ tuyến tính giữa các đặc trưng đầu vào với giá phòng. Chính vì vậy, để tiếp tục khai thác các mối quan hệ tuyến tính và đồng thời giảm thiểu sai số dự đoán, nhóm đã sử dụng thêm Lasso Regression và Ridge Regression.

Tuy nhiên, mặc dù mô hình tuyến tính có ý nghĩa thống kê, nhưng chưa đủ tốt trong thực tiễn. Kết quả thực nghiệm với hệ số R^2 Adjusted chỉ khoảng 55% và MAE lên đến khoảng 540.000 cho thấy các mô hình hồi quy vẫn chưa mô tả đầy đủ sự biến động và tính phức tạp của giá phòng. Điều này gợi ý rằng ngoài quan hệ tuyến tính, dữ liệu có thể còn mang tính phi tuyến hoặc tồn tại các tương tác giữa đặc trưng mà các mô hình tuyến tính khó nắm bắt. Từ đó, nhóm quyết định áp dụng mô hình khác như Random Forest.

Random Forest Regressor thể hiện vượt trội với MAE giảm mạnh xuống còn khoảng 100.000, đồng thời R^2 Adjusted tăng vọt lên đến 0.96, tức là mô hình có khả năng giải thích đến 96% phương sai của dữ liệu. Đây là mức cải thiện đáng kể, cho thấy Random Forest phù hợp hơn nhiều so với các mô hình hồi quy tuyến tính trong bài toán này. Nó thể hiện ưu thế rõ rệt nhờ khả năng khai thác tốt các mối quan hệ phi tuyến và mối tương quan phức tạp giữa các đặc trưng, tự động chọn lọc đặc trưng quan trọng và xử lý hiệu quả các biến nhị phân mà không cần chuẩn hóa dữ liệu. Chính vì những yếu tố đó mà Random Forest Regressor phù hợp hơn rất nhiều so với các mô hình hồi quy trong bài toán dự đoán giá phòng dựa trên dữ liệu nhiều chiều và thực tế của nhóm.

4 Kết luận và hướng phát triển

4.1 Kết luận

Nhóm đã xây dựng bộ dữ liệu về các khách sạn ven biển tại Việt Nam, từ đó triển khai mô hình dự đoán giá phòng dựa trên các đặc trưng đầu vào. Dữ liệu được lấy trực tiếp từ nền tảng Booking.com bằng kỹ thuật web scraping sử dụng Selenium, và xử lý theo kiến trúc Medallion. Mô hình Random Forest Regressor được lựa chọn sau khi thử nghiệm và so sánh với nhiều mô hình hồi quy, cho kết quả vượt trội với độ chính xác cao,

phản ánh chất lượng của cả quá trình thu thập và xử lý dữ liệu. Bên cạnh bài toán với chủ đề giá mà nhóm đã triển khai trong đề tài này, bộ dữ liệu còn được kỳ vọng sẽ phục vụ cho nhiều mục đích học thuật và nghiên cứu khác trong tương lai về lĩnh vực lưu trú du lịch.

4.2 Ưu và nhược điểm

Đồ án có nhiều điểm mạnh nổi bật. Bộ dữ liệu được xây dựng phong phú, phản ánh sát thực tế. Đặc biệt, mặc dù dữ liệu được thu thập cho các thời điểm đặt phòng trong tương lai gần, nhóm đã xử lý cẩn thận yếu tố thời gian, đảm bảo tính đúng đắn, độ tin cậy và khả năng ứng dụng thực tế. Hệ thống thu thập tự động có khả năng mô phỏng người dùng và xử lý lỗi tốt, cơ chế lưu an toàn, quy trình tiền xử lý bài bản, và mô hình học máy được đánh giá kỹ lưỡng.

Tuy vậy, vẫn còn tồn đọng một số hạn chế. Việc thu thập dữ liệu mất nhiều thời gian do phải thao tác qua trình duyệt thực và chèn độ trễ để tránh bị chặn. Hệ thống phụ thuộc lớn vào cấu trúc HTML của Booking.com nên dễ bị ảnh hưởng nếu giao diện thay đổi. Ngoài ra, dữ liệu vẫn còn thiếu ở một số trường và chưa bao phủ hết các mùa trong năm. Nguồn dữ liệu hiện tại cũng chỉ giới hạn từ một nền tảng, chưa phản ánh đầy đủ thị trường lưu trú.

4.3 Hướng phát triển

Trong thời gian tới, nhóm dự kiến cải thiện bằng cách tăng tốc độ thu thập qua xử lý song song, tách riêng cấu hình các phần tử HTML để dễ bảo trì khi Booking.com thay đổi giao diện, đồng thời tích hợp log chi tiết và loại bỏ dữ liệu trùng lặp để kiểm soát quá trình tốt hơn. Ngoài ra, việc mở rộng dữ liệu từ các nền tảng khác như Agoda hay Traveloka, cũng như bổ sung dữ liệu bao phủ các mùa trong năm sẽ giúp nâng cao độ chính xác và khả năng ứng dụng thực tiễn của mô hình.

Tài liệu tham khảo

[1] Selenium with Python. URL: selenium-python.readthedocs.io.

[2] Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow - Aurélien Géron 2nd edition.

[3] J. Pei J. Han and M. Kamber. 2012. Data Mining - Concept and Techniques 3rd edition.

[4] An Introduction to Statistical Learning: with Applications in Python (ISLP) - Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, Jonathan Taylor.

Công việc	Thành viên thực hiện	Mức độ hoàn thành
- Thu thập dữ liệu	Huỳnh Phát Đạt	100%
- Tiền xử lý dữ liệu	Bùi Quốc Bảo	100%
- Khám phá và phân dữ liệu	Lê Minh Khôi	100%
- Khảo sát. - Viết báo cáo. - Đánh giá dữ liệu. - Làm slide thuyết trình. - Xây dựng và đánh giá mô hình.	Lê Minh Khôi Bùi Quốc Bảo Huỳnh Phát Đạt	100%

Bảng phân công công việc